Relatório de limpeza dos dados

Projeto: Enchentes no RS, dashboard interativo
Equipe: Sofia e Bernardo
Disciplina: Coleta, Preparação e Análise de Dados (PUCRS)
Data: 09/11/2026

1. Objetivo

Este relatório mostra como os dados do INCT SiMAI foram limpos antes de serem usados no dashboard, quais inconsistências foram encontradas e o que foi decidido para cada uma. No final também estão as conferências feitas nas bases externas (UFRGS, IBGE e ANA).

2. Dados usados

• **data.json do INCT SiMAI:** simulação de alagamento dos 94 bairros de Porto Alegre, nos níveis do Guaíba de 3,0 m a 10,0 m (71 níveis). Base da Tela 1.

• **UFRGS (Zenodo):** tabela dos 139 municípios da região do Guaíba atingidos em maio de 2024. Baixada por API com o script coleta_ufrgs.py.

• **IBGE (SIDRA):** população dos 497 municípios do RS no Censo 2022. Baixada por API com o script coleta_ibge.py.

• **ANA:** nível do Guaíba na estação Cais Mauá, a cada 15 minutos, de 2014 a 2025. Baixado por API com o script coleta_ana.py.

O arquivo original do INCT não foi alterado. Ele fica em dados/originais e a versão limpa foi salva em dados/processados/inct_limpo.json. A limpeza está no notebook notebooks/limpeza.ipynb.

3. Etapas da limpeza

A limpeza foi feita em 8 blocos, na ordem: conhecer os dados, arrumar o formato, testar, corrigir e salvar.

Bloco	O que foi feito	Resultado
1. Carregar e conhecer os dados	JSON transformado em tabela (uma linha por bairro em cada nível). Uso de shape, head, info e describe.	6674 linhas (71 níveis x 94 bairros). Nenhum valor vazio. O nível estava em texto.
2. Padronizar formatos	Nível transformado de texto em número (3_0m passou a ser 3.0). Conferência da ordem dos bairros em cada nível.	Morro Santana fora de ordem no nível 5,3.
3. Valores faltantes	isnull().sum()	Nenhum valor vazio.
4. Duplicatas	duplicated() na linha inteira e só em nível e bairro.	Nenhuma repetição.
5. Erros de digitação	Contagem de bairros e conferência dos nomes.	94 bairros, cada um nos 71 níveis. Nenhum nome escrito de dois jeitos.
6. Inconsistências	Comparação de cada nível com o anterior, bairro por bairro. Gráfico dos bairros com queda.	12 quedas em 5 bairros, de 4 tipos.
7. Conferir os cálculos	Porcentagem e população afetada recalculadas e comparadas com o arquivo.	As duas colunas estavam sempre arredondadas para cima.
8. Salvar os dados limpos	Tabela salva em JSON, com as colunas originais e a coluna corrigido.	inct_limpo.json com 6674 linhas e 11 colunas.

4. Inconsistências encontradas no arquivo do INCT

Para cada inconsistência: onde aparece, por que é um problema e o que foi decidido.

#	Onde aparece	Por que é um problema	Decisão e justificativa
1	Coluna nivel, todas as linhas (ex.: "3_0m")	Texto não permite conta nem gráfico. Em texto o 10 m fica antes do 3 m.	Corrigir: transformar em número. O valor estava certo, só o formato estava errado.
2	Nível 5,3 m, bairro Morro Santana	Aparece no fim da lista, fora da ordem dos outros 70 níveis.	Manter e avisar. Os números estão certos e o código usa o nome do bairro e o nível, não a posição da linha.
3	Lageado 8,1 m (108, 0, 110); Rubem Berta 8,8 m (252, 0, 285); Centro Histórico 9,7 e 9,8 m (2050, 0, 0, 2130)	Os prédios alagados caem para zero com o rio subindo e depois voltam. Isso não é possível.	Interpolar. O valor certo deve estar entre o nível de antes e o de depois. Resultado: 109, 268, 2076 e 2103.
4	Espírito Santo 4,7 m (46, 2101, 47)	Pico isolado (outlier), fora do padrão do bairro.	Interpolar, pelo mesmo motivo. Resultado: 46.
5	Espírito Santo de 3,0 a 3,4 m (637 prédios, depois 25 em 3,5 m)	Mais prédios alagados com o rio mais baixo do que com o rio a 10 m.	Substituir pelo valor normal mais próximo (25). Não dá para interpolar porque não existe nível antes do 3,0.
6	Arquipélago, vários níveis (entre 4674 e 4688 prédios)	Oscila e às vezes cai (6 quedas).	Manter e avisar. A diferença é menor que 0,3% do bairro, não muda o resultado e não dá para saber qual valor é o certo.
7	Coluna percentage, todas as linhas (ex.: Santa Tereza 3,2 m: 1 prédio de 15.906 aparece com 1%)	A porcentagem está sempre arredondada para cima, sem casas decimais.	Corrigir: recalcular com casas decimais (prédios alagados / total x 100). A fórmula está no enunciado.
8	Coluna affected_population, todas as linhas (ex.: Santa Tereza 3,2 m: 314 pessoas por 1 prédio)	Também arredondada para cima e calculada com a porcentagem arredondada.	Corrigir: recalcular com a porcentagem nova. Santa Tereza passou de 314 para 1 pessoa.
9	População afetada em geral	Supõe que as pessoas estão espalhadas igualmente por todos os prédios, até os não residenciais.	Manter e avisar no dashboard. Não temos como saber quem mora em cada prédio.

5. Impacto da limpeza

• 10 linhas tiveram os prédios alagados corrigidos. Elas ficaram marcadas na coluna corrigido.

• No nível 5,3 m, o mais próximo da enchente de 2024, o total de pessoas afetadas em Porto Alegre passou de 138.414 para 136.373.

• A curva de pessoas afetadas por nível deixou de ter quedas (antes caía nos níveis 9,7 e 9,8 por causa do Centro Histórico).

6. Conferência das bases externas

Base	O que foi conferido	O que foi encontrado	Decisão
UFRGS	Vazios e municípios repetidos nas colunas usadas	Victor Graeff sem informação de escolas e unidades de saúde. Nenhum município repetido.	Manter vazio. Preencher com zero seria afirmar que nenhuma escola foi atingida.
UFRGS	Coluna de domicílios	Números com ponto no lugar errado (ex.: 91.915 em Porto Alegre).	A coluna não foi usada nos gráficos.
UFRGS x IBGE	População de cada município nas duas fontes	Só Putinga é diferente (3650 na UFRGS e 3747 no IBGE).	Usar a população do IBGE, que é a fonte oficial.
ANA	Repetições e valores fora do padrão	Nenhuma medição repetida. Medições isoladas erradas do sensor (ex.: 3,90 m no meio de medições de 1 m, em 2017).	Usar a mediana de cada dia, que ignora os valores isolados. O maior valor passou a ser 3,42 m (novembro de 2023).

Base	O que foi conferido	O que foi encontrado	Decisão
ANA	Período coberto	A estação parou de medir em 2 de maio de 2024, com o rio a 3,69 m, antes do pico de 5,35 m.	Manter e avisar no gráfico (2024 aparece como incompleto).

7. Limitações

• Os números do INCT são estimativas de uma simulação, não contagens oficiais.

• A população afetada supõe pessoas espalhadas igualmente por todos os prédios do bairro.

• Os arquivos de mapa da UFRGS (geopandas) não foram usados nesta fase, porque esse conteúdo ainda não foi visto em aula.

8. Uso de inteligência artificial

Usamos o Claude (IA) como apoio para entender o enunciado, sugerir o código da limpeza, dos scripts de coleta e do EDA com base nos materiais das aulas e dos laboratórios, e organizar este relatório. A equipe rodou o código, conferiu os resultados e as decisões de limpeza.