COLETA, PREPARAÇÃO E ANÁLISE DE DADOS

Relatório de limpeza dos dados

PROJETO
Enchentes no RS, dashboard interativo

EQUIPE
Sofia e Bernardo

DISCIPLINA
Coleta, Preparação e Análise de Dados (PUCRS)

DATA
09/11/2026

6.674	12	10	136.373
linhas na tabela (71 níveis x 94 bairros)	quedas em 5 bairros, de 4 tipos	linhas com os prédios alagados corrigidos	pessoas afetadas a 5,3 m (antes: 138.414)

SEÇÃO 01

Objetivo

Este relatório mostra como os dados do INCT SiMAI foram limpos antes de serem usados no dashboard, quais inconsistências foram encontradas e o que foi decidido para cada uma. No final também estão as conferências feitas nas bases externas (UFRGS, IBGE e ANA).

SEÇÃO 02

Dados usados

- **data.json do INCT SiMAI:** simulação de alagamento dos 94 bairros de Porto Alegre, nos níveis do Guaíba de 3,0 m a 10,0 m (71 níveis). Base da Tela 1.
- **UFRGS (Zenodo):** tabela dos 139 municípios da região do Guaíba atingidos em maio de 2024. Baixada por API com o script `coleta_ufrgs.py`.
- **IBGE (SIDRA):** população dos 497 municípios do RS no Censo 2022. Baixada por API com o script `coleta_ibge.py`.
- **ANA:** nível do Guaíba na estação Cais Mauá, a cada 15 minutos, de 2014 a 2025. Baixado por API com o script `coleta_ana.py`.

> O arquivo original do INCT não foi alterado. Ele fica em `dados/originais` e a versão limpa foi salva em `dados/processados/inct_limpo.json`. A limpeza está no notebook `notebooks/limpeza.ipynb`.

SEÇÃO 03

Etapas da limpeza

A limpeza foi feita em 8 blocos, na ordem: conhecer os dados, arrumar o formato, testar, corrigir e salvar.

	O QUE FOI FEITO	RESULTADO
1	**Carregar e conhecer os dados** JSON transformado em tabela (uma linha por bairro em cada nível). Uso de `shape`, `head`, `info` e `describe`.	6674 linhas (71 níveis x 94 bairros). Nenhum valor vazio. O nível estava em texto.
2	**Padronizar formatos** Nível transformado de texto em número (`3_0m` passou a ser `3.0`). Conferência da ordem dos bairros em cada nível.	Morro Santana fora de ordem no nível 5,3.

3	**Valores faltantes** `isnull().sum()`	Nenhum valor vazio.
4	**Duplicatas** `duplicated()` na linha inteira e só em nível e bairro.	Nenhuma repetição.
5	**Erros de digitação** Contagem de bairros e conferência dos nomes.	94 bairros, cada um nos 71 níveis. Nenhum nome escrito de dois jeitos.
6	**Inconsistências** Comparação de cada nível com o anterior, bairro por bairro. Gráfico dos bairros com queda.	12 quedas em 5 bairros, de 4 tipos.
7	**Conferir os cálculos** Porcentagem e população afetada recalculadas e comparadas com o arquivo.	As duas colunas estavam sempre arredondadas para cima.
8	**Salvar os dados limpos** Tabela salva em JSON, com as colunas originais e a coluna `corrigido`.	`inct_limpo.json` com 6674 linhas e 11 colunas.

SEÇÃO 04

Inconsistências encontradas no arquivo do INCT

Para cada inconsistência: onde aparece, por que é um problema e o que foi decidido.

	ONDE APARECE E POR QUE É UM PROBLEMA	DECISÃO E JUSTIFICATIVA
1	**Coluna `nivel`, todas as linhas (ex.: `"3_0m"`)** Texto não permite conta nem gráfico. Em texto o 10 m fica antes do 3 m.	**Corrigir:** transformar em número. O valor estava certo, só o formato estava errado.
2	**Nível 5,3 m, bairro Morro Santana** Aparece no fim da lista, fora da ordem dos outros 70 níveis.	**Manter e avisar.** Os números estão certos e o código usa o nome do bairro e o nível, não a posição da linha.
3	**Lageado 8,1 m (108, 0, 110); Rubem Berta 8,8 m (252, 0, 285); Centro Histórico 9,7 e 9,8 m (2050, 0, 0, 2130)** Os prédios alagados caem para zero com o rio subindo e depois voltam. Isso não é possível.	**Interpolar.** O valor certo deve estar entre o nível de antes e o de depois. Resultado: 109, 268, 2076 e 2103.
4	**Espírito Santo 4,7 m (46, 2101, 47)** Pico isolado (outlier), fora do padrão do bairro.	**Interpolar,** pelo mesmo motivo. Resultado: 46.
5	**Espírito Santo de 3,0 a 3,4 m (637 prédios, depois 25 em 3,5 m)** Mais prédios alagados com o rio mais baixo do que com o rio a 10 m.	**Substituir** pelo valor normal mais próximo (25). Não dá para interpolar porque não existe nível antes do 3,0.
6	**Arquipélago, vários níveis (entre 4674 e 4688 prédios)** Oscila e às vezes cai (6 quedas).	**Manter e avisar.** A diferença é menor que 0,3% do bairro, não muda o resultado e não dá para saber qual valor é o certo.
7	**Coluna `percentage`, todas as linhas (ex.: Santa Tereza 3,2 m: 1 prédio de 15.906 aparece com 1%)** A porcentagem está sempre arredondada para cima, sem casas decimais.	**Corrigir:** recalcular com casas decimais (prédios alagados / total x 100). A fórmula está no enunciado.
8	**Coluna `affected_population`, todas as linhas (ex.: Santa Tereza 3,2 m: 314 pessoas por 1 prédio)** Também arredondada para cima e calculada com a porcentagem arredondada.	**Corrigir:** recalcular com a porcentagem nova. Santa Tereza passou de 314 para 1 pessoa.
9	**População afetada em geral** Supõe que as pessoas estão espalhadas igualmente por todos os prédios, até os não residenciais.	**Manter e avisar** no dashboard. Não temos como saber quem mora em cada prédio.

SEÇÃO 05

Impacto da limpeza

- 10 linhas tiveram os prédios alagados corrigidos. Elas ficaram marcadas na coluna `corrigido`.
- No nível 5,3 m, o mais próximo da enchente de 2024, o total de pessoas afetadas em Porto Alegre passou de 138.414 para 136.373.
- A curva de pessoas afetadas por nível deixou de ter quedas (antes caía nos níveis 9,7 e 9,8 por causa do Centro Histórico).

SEÇÃO 06

Conferência das bases externas

BASE	O QUE FOI CONFERIDO E ENCONTRADO	DECISÃO
UFRGS	**Vazios e municípios repetidos nas colunas usadas**	
	Victor Graeff sem informação de escolas e unidades de saúde. Nenhum município repetido.	**Manter vazio.** Preencher com zero seria afirmar que nenhuma escola foi atingida.
UFRGS	**Coluna de domicílios**	
	Números com ponto no lugar errado (ex.: 91.915 em Porto Alegre).	A coluna não foi usada nos gráficos.
UFRGS x IBGE	**População de cada município nas duas fontes**	
	Só Putinga é diferente (3650 na UFRGS e 3747 no IBGE).	**Usar a população do IBGE,** que é a fonte oficial.
ANA	**Repetições e valores fora do padrão**	
	Nenhuma medição repetida. Medições isoladas erradas do sensor (ex.: 3,90 m no meio de medições de 1 m, em 2017).	**Usar a mediana de cada dia,** que ignora os valores isolados. O maior valor passou a ser 3,42 m (novembro de 2023).
ANA	**Período coberto**	
	A estação parou de medir em 2 de maio de 2024, com o rio a 3,69 m, antes do pico de 5,35 m.	**Manter e avisar** no gráfico (2024 aparece como incompleto).

SEÇÃO 07

Limitações

- Os números do INCT são estimativas de uma simulação, não contagens oficiais.
- A população afetada supõe pessoas espalhadas igualmente por todos os prédios do bairro.
- Os arquivos de mapa da UFRGS (geopandas) não foram usados nesta fase, porque esse conteúdo ainda não foi visto em aula.